

Marcin Łykowski

numer albumu: 47168

kierunek studiów: Informatyka

specjalność: Inteligencja obliczeniowa

forma studiów: studia niestacjonarne

**ROZPOZNAWANIE TABLIC REJESTRACYJNYCH POJAZDÓW NA
OBRAZACH Z KAMERY SAMOCHODOWEJ**

**RECOGNITION OF VEHICLE LICENSE PLATES ON IMAGES FROM A
CAR CAMERA**

praca dyplomowa magisterska

napisana pod kierunkiem:

dr hab. inż. Przemysław Kłęska

Katedra Metod Sztucznej Inteligencji i Matematyki Stosowanej

Data wydania tematu pracy: 30.03.2022

Data dopuszczenia pracy do egzaminu:
(uzupełnia pisemnie Dziekanat)

Szczecin, 2022

Oświadczenie autora pracy dyplomowej

Oświadczam, że praca dyplomowa magisterska pn. *Rozpoznawanie tablic rejestracyjnych pojazdów na obrazach z kamery samochodowej* napisana pod kierunkiem dr hab. inż. Przemysława Klęska jest w całości moim samodzielnym autorskim opracowaniem sporządzonym przy wykorzystaniu wykazanej w pracy literatury przedmiotu i materiałów źródłowych. Złożona w dziekanacie Wydziału Informatyki treść mojej pracy dyplomowej w formie elektronicznej jest zgodna z treścią w formie pisemnej.

Oświadczam ponadto, że złożona w dziekanacie praca dyplomowa ani jej fragmenty nie były wcześniej przedmiotem procedur procesu dyplomowania związanych z uzyskaniem tytułu zawodowego w uczelniach wyższych.

Podpis autora:

Szczecin, dnia:

Streszczenie

W tym miejscu trzeba napisać streszczenie pracy w języku polskim. Zawiera krótką charakterystykę dziedziny, przedmiotu i wyników zaprezentowanych w pracy. Maksymalnie 1/2 strony.

słowa kluczowe: np. informatyka, sterowanie, grafika komputerowa

Abstract

The abstract's purpose, which should not exceed 150 words, is to provide sufficient information to allow potential readers to decide on the thesis's relevance—a maximum of half the page.

keywords: e.g.: computer science, control, computer graphics

Spis treści

Wstęp	7
1 Wprowadzenie teoretyczne	9
1.1 Przegląd istniejących metod detekcji tablic rejestracyjnych	11
1.1.1 Metody oparte na krawędziach (ang. <i>Edge based</i>)	11
1.1.2 Metody oparte na kolorach (ang. <i>Color based</i>)	13
1.1.3 Metody oparte na teksturach (ang. <i>Texture based</i>)	14
1.1.4 Klasyfikatory	14
1.1.5 Metody głębokiego uczenia (ang. <i>Deep learning</i>)	18
1.2 Przegląd istniejących metod segmentacji tablic rejestracyjnych	19
1.2.1 Binaryzacja	20
1.2.2 Metoda k-średnich	22
1.2.3 Metoda rzutów jasności	22
1.2.4 Metoda elementów połączonych (ang. <i>Connected components</i>)	22
1.3 Przegląd istniejących metod rozpoznawania tablic rejestracyjnych	22
1.3.1 OCR	22
1.3.2 TEMPLATE AND PATTERN MATCHING TECHNIQUES	22
2 Zebranie materiału uczącego	23
3 Opracowany algorytm	25
3.1 Proces uczenia klasyfikatora	25
3.2 Schemat algorytmu	25
3.3 Biblioteki użyte w programie	25
3.3.1 OpenCV	25
3.3.2 Tesseract OCR	26
3.3.3 Numpy	26
3.3.4 Sklearn	26
3.3.5 Matplotlib	26
4 Wyniki badań	27

Podsumowanie	28
Spis literatury	31
Książki	31
Artykuły	31
Źródła internetowe i inne	33

Wstęp

W dzisiejszych czasach ludzka praca stanowi jeden z największych składników kosztów dla wielu przedsiębiorstw. Taki stan rzeczy prowadzi do poszukiwania rozwiązań mających na celu zautomatyzowanie najbardziej powtarzalnych czynności. Potwierdza to wzrost zainteresowania na przestrzeni ostatnich lat zagadnieniami takimi jak uczenie maszynowe czy widzenie komputerowe. Jedną z gałęzi gospodarki, w której tego rodzaju automatyzacja jest zauważalna nawet dla osób niezwiązanych z branżą, jest transport drogowy. Nieustannie zwiększająca się liczba aut poruszających się po drogach, wzrost sieci dróg i autostrad niejako samoistnie wymusiła próby zautomatyzowania pewnych czynności.

Jednym z najczęściej poruszanych zagadnień jest problem rozpoznawania tablic rejestracyjnych (ang. *Licence Plate Recognition* - LPR). Do zadań takich systemów należy wykrycie na obrazie obszarów, w których znajdują się tablice rejestracyjne. Dokładność uzależniona jest od wielu czynników, takich jak jakość obrazu, prędkość pojazdu, warunki atmosferyczne lub pora dnia.

Celem niniejszej pracy jest przedstawienie tematyki rozpoznawania tablic rejestracyjnych. Wybór takiego zagadnienia w niniejszej pracy dyplomowej, motywuje własnymi zainteresowaniami zarówno na polu motoryzacyjnym jak i również uczenia maszynowego oraz widzenia komputerowego. W skład zakresu pracy wchodzi:

- Omówienie wybranych algorytmów z zakresu przetwarzania obrazów i uczenia maszynowego, potrzebnych do realizacji postawionego zadania.
- Przygotowania odpowiedniego materiału (sekwencje wideo) na potrzeby uczenia maszynowego i testowania.
- Przedstawienie ostatecznego schematu algorytmicznego dla całego procesu.
- Przeprowadzenie eksperymentów, pomiary dokładności i czasów wykonania, wnioski końcowe.

W pierwszej części pracy przedstawione zostaną najczęściej wykorzystywane techniki uczenia maszynowego i widzenia komputerowego do osiągnięcia wysokiej jakości systemu automatycznego rozpoznawania tablic rejestracyjnych. W drugiej części pracy zostanie przedstawiony stworzony program komputerowy do realizacji zadania rozpoznawania tablic rejestracyjnych. Część ta zawiera szczegółowy opis bibliotek wykorzystanych do realizacji przedstawionego zadania oraz implementacji opracowanego algorytmu. Przedstawiono również etapy pozyskania zbioru uczącego dla opracowanego mechanizmu. Po opisaniu opracowanego procesu, zostaną zaprezentowane wyniki dla wyuczonego klasyfikatora.

W przedstawionej pracy udało się zrealizować przedstawione zadanie. Do realizacji programu wykorzystano język programowania Python w wersji 3.8. Klasyfikator oparty

został o cechy Haara (ang. *Haar-like features*). Praca ma charakter eksperymentalny. Z tego powodu oraz z racji ograniczonych zasobów, algorytm ma swoje niedoskonałości. W podsumowaniu pracy zaprezentowano możliwości dalszego rozwoju klasyfikatora.

1. Wprowadzenie teoretyczne


Na przestrzeni ostatnich lat stosowanie Systemów Automatycznego Rozpoznawania Tablic Rejestracyjnych (ARTR)(ang. *Automatic Licence Plate Recognition - ALPR*) stało się znacznie bardziej powszechne. W większości dużych miast istnieją parkingi, gdzie po umieszczeniu opłaty za postój, przy zbliżeniu się do wyjazdu, szlaban otwiera się automatycznie po rozpoznaniu numeru rejestracyjnego pojazdu, w którym się poruszamy. W obecnych czasach wszystkie nowoczesne systemy do zarządzania i sterowania ruchem drogowym oparte są o technologie ARTR. Instytucje takie jak służby drogowe, dzięki rejestrowanym i przetwarzanym w czasie rzeczywistym ogromnym ilościom danych, są w stanie odpowiednio szybko reagować na wydarzenia na drogach takie jak kolizje, korki lub innego rodzaju utrudnienia. Innym z możliwych przykładów zastosowania wspomnianych systemów są odcinkowe pomiary prędkości, opłaty za przejazd płatnymi drogami lub wykrywanie kierowców łamiących przepisy. Dzięki nieustannemu rozwojowi technologii i co raz wydajniejszym komputerom, systemy stają się tańszą i łatwiej dostępną alternatywą dla systemów opartych na RFID (ang. *Radio-frequency identification*), które to wymagają specjalnej etykiety do prawidłowego działania.

Rozpoznawanie tablic rejestracyjnych jest techniką polegającą na wykryciu i odczytaniu znaków z tablicy rejestracyjnych na podstawie zarejestrowanego obrazu. Do tego celu wykorzystywany jest aparat o wysokiej rozdzielczości oraz odpowiedni program komputerowy. Oprogramowanie otrzymuje na wejściu cyfrową reprezentację obrazu. Dla zdjęć kolorowych każdy piksel opisany jest wartościami z palety barw RGB reprezentującymi jego barwę oraz współrzędnymi umiejscowienia w obrazie. Dla zdjęć monochromatycznych barwy opisywane są najczęściej za pomocą wartości luminacji obrazu.

W procesie automatycznego rozpoznawania tablic rejestracyjnych pozyskany obraz jest odpowiednio przetwarzany. Przed przejściem do rozpoznawania, obraz często jest konwertowany do skali szarości i filtrowany za pomocą filtrów np. (Gausa lub średnio-przepustowego) w celu redukcji szumu. W procesie tym można wyróżnić trzy etapy [1]:

- **detekcję** - określenie położenia tablicy rejestracyjnej w analizowanym obrazie
- **segmentację** - wyodrębnienie pojedynczych znaków na fragmencie obrazu ze zlokalizowaną tablicą
- **identyfikację** - rozpoznanie każdego ze znaków i przedstawienie ich w formie tekstowej, którą można później wykorzystać do dalszych działań w zależności od przeznaczenia systemu

Na rysunku 1.1 przedstawiono graficzną reprezentację powyższego procesu.



Rysunek 1.1: Etapy procesu automatycznego rozpoznawania tablic rejestracyjnych (źródło: opracowanie własne)

Kolejne etapy korzystają z wyników uzyskanych w poprzednich krokach, co oznacza, że błąd powstały we wcześniejszej fazie, będzie rzutował na jakość działania całego systemu. W wielu systemach zanim dojdzie do rozpoznawania tablicy rejestracyjnej, obraz jest w pierwszej kolejności odpowiednio przetwarzany. Jednymi z najpowszechniej stosowanych czynności są skalowanie obrazu, modyfikacje jasności oraz redukcja zakłóceń. W zależności od wymagań stawianych przed danym mechanizmem i środowiskiem jego działania, czynności te mogą znacznie się od siebie różnić. Najbardziej podstawowe systemy wymagają, aby pojazd znajdował się nieruchomo w określonym miejscu. Tego typu rozwiązania najczęściej stosowane są na parkingach, gdzie szlaban otwiera się po odczycie numerów rejestracyjnych pojazdu i potwierdzeniu opłaty za postój w zewnętrznej bazie danych. Takie systemy pracują z reguły w środowisku o niskim poziomie zakłóceń wynikających z warunków atmosferycznych i oświetlenia. Obecnie na rynku znajduje się wiele komercyjnych rozwiązań, które oferują wysoką dokładność (powyżej 95%) dla tego rodzaju detekcji. Taki rodzaj systemów ARTR nazywany systemami statycznymi. Dużo większą

złożonością charakteryzują się systemy dynamiczne, w których znacznie większą rolę odgrywają zakłócenia wynikające ze zmiennych warunków oświetlenia. W obecnych czasach stworzenie dynamicznego systemu ARTR o wysokiej dokładności wciąż stanowi wyzwanie i jest tematem wielu prac naukowych. Celem niniejszej pracy jest analizowanie obrazów pochodzących z kamery samochodowej, co zdecydowanie sprawia, że jest to system dynamiczny. Poniżej przedstawiono najczęściej stosowane metody widzenia komputerowego w systemach ARTR.

1.1 Przegląd istniejących metod detekcji tablic rejestracyjnych

Zgodnie ze słownikiem języka polskiego, definicja tablicy rejestracyjnej brzmi następująco:

Definicja 1.1.1 — Tablica rejestracyjna. Płytką zawierającą numery identyfikacyjne pojazdu, umieszczana z przodu i z tyłu pojazdu.

Dla programu komputerowego powyższe zdanie nie jest zrozumiałe. W zadaniu detekcji tablicy rejestracyjnej, wymagane jest, aby maszyna “zrozumiała” jakich obiektów należy szukać. W kontekście detekcji, za definicję można uznać “prostokątny obszar, z dużym zagęszczeniem horyzontalnych i wertykalnych krawędzi”[24]. W oparciu o powyższe cechy zaprezentowano wiele algorytmów do rozwiązania zadania wykrywania tablic rejestracyjnych. Część z nich wywodzi się z tradycyjnych metod widzenia komputerowego i metod głębokiego uczenia. Każda z metod ma swoje zalety, ale również często ograniczenia. W związku z tym, trudno jednoznacznie stwierdzić, która z metod jest najbardziej efektywna.

Detekcja numerów rejestracyjnych jest wyzywającym zadaniem ze względu na poniższe czynniki:

- tablica rejestracyjna zajmuje niewielki obszar na zdjęciu
- istnienie ogromnej ilości formatów tablic rejestracyjnych (w zależności od kraju rejestracji lub rodzaju pojazdu)
- słabe oświetlenie, rozmazany obraz, refleksy świetlne
- ruch pojazdu, zabrudzone tablice

Tradycyjne metody widzenia komputerowego oparte są na cechach takich jak kształt, kolor, symetria, tekstury itp.[19]. W celu uzyskania lepszych wyników, spotyka się rozwiązania, w których łączy się wiele technik. Poniżej wyróżniono najczęściej stosowane metody w detekcji tablic rejestracyjnych.

1.1.1 Metody oparte na krawędziach (ang. *Edge based*)

Biorąc pod uwagę, że tablica rejestracyjna jest prostokątem o znanych proporcjach, większość badań bazuje na podejściu opartym o wykrywanie krawędzi. W większości przypadków kolor tablicy rejestracyjnej jest różny od koloru pojazdu. Dzięki temu, granice tablicy zostają uznane za krawędzie. Wiele metod wykorzystuje filtr Sobela. Jego działania polega dyskretnym różniczkowaniu i aproksymacji pochodnych kierunkowych intensywności obrazu. Filtr ten składa się z dwóch macierzy o wymiarach 3x3 (1.2) służących do detekcji krawędzi horyzontalnych i wertykalnych.

-1	0	+1
-2	0	+2
-1	0	+1

G_x

+1	+2	+1
0	0	0
-1	-2	-1

G_y

Rysunek 1.2: Macierze detektora krawędzi Sobela (źródło: opracowanie własne)

Zaletą takiego podejścia jest niewątpliwa łatwość użycia, natomiast jedną z głównych wad jest jego wrażliwość na szum.

Często wykorzystywaną metodą do wykrywania krawędzi obiektów w obrazach jest *Binary Image Processing*. Technika ta polega na sprowadzeniu obrazu do postaci, w której kolory pikseli przyjmują tylko dwie wartości - czarną lub białą. Osiąga się to za pomocą ustalenia progu, który determinuje kolor piksela. Proóg wyznaczany jest na podstawie histogramu obrazu w odcieniach szarości. Metoda ta jest użyteczna, ze względu na fakt łatwego odseparowania obiektu od tła. Wykorzystuje ona założenie, że krawędzie tablicy są proste i poziome. Przy zdeformowanych lub zabrudzonych tablicach, algorytm ten nie osiąga zadowalających wyników.

Inną stosowaną metodą do wykrywania linii na obrazach binarnych jest transformata Hougha [6]. Motywacją do jej opracowania była metoda siłowa (ang. *Brute force*), która jest jednak znacznie bardziej zasobożerna. Złożoność algorytmu siłowego wynosi $O(n^3)$. Transformata Hougha polega na twierdzeniu, że każda prosta może być jednoznacznie przedstawiona za pomocą dwóch parametrów. Przestrzeń tych parametrów to właśnie przestrzeń Hougha. Najczęściej używanymi parametrami są współczynniki ρ i α z równania prostej w postaci normalnej (1.1).

$$x \cos \alpha + y \sin \alpha = \rho \quad (1.1)$$

W powyższym równaniu ρ jest promieniem wodzącym, natomiast α kątem tworzonym przez ρ z osią X. W związku z powyższym, jest to algorytm o liniowej złożoności obliczeniowej. Można wykazać następujące własności transformacji Hougha:

Twierdzenie 1.1.1 Prostej przestrzeni kartezjańskiej odpowiada w przestrzeni Hougha punkt, natomiast punktowi przestrzeni kartezjańskiej odpowiada w przestrzeni Hougha sinusoidalna krzywa. Punkty leżące na tej samej prostej korespondują z sinusoidami przechodzącymi przez wspólny punkt w przestrzeni Hougha [20].

Zasadę transformacji ilustruje rysunek 1.3.



Rysunek 1.3: Transformata Hougha (źródło: [11])

Innym spotykanym podejściem [8] jest stosowanie dwóch algorytmów. Pierwszy z nich ma za zadanie wyodrębnić odcinki linii i pogrupować je na podstawie wcześniej ustalonego zbioru warunków geometrycznych. Drugi znajduje obszary o najwyższym zagęszczeniu pionowych krawędzi. Dzięki takiemu spojrzeniu na przedstawiony problem, uzyskane wyniki mają wysoką dokładności, szczególnie dla pojazdów znajdujących się w ruchu. Metody oparte na krawędziach są stosowane w wielu rozwiązaniach ze względu na ich szybkość działania i prostotę. Jednakże, rozwiązania te są silnie wrażliwe na niepożądane krawędzie i nie sprawdzają się w rozmytych i złożonych obrazach.

1.1.2 Metody oparte na kolorach (ang. *Color based*)

Metody oparte na kolorach bazują na fakcie, że kolor tablicy jest różny od koloru tła pojazdu. Dla tej grupy rozwiązań, zamiast modelu barw RGB, stosuje się model HSL oparty o nasycenie koloru. Model ten jest jednak wrażliwy na szum.

Często metody wykorzystujące kolor tablicy rejestracyjnej są używane do wyselekcjonowania kandydatów. Innymi słowy, oznacza to wybranie obszarów obrazu, w których może znajdować się tablica rejestracyjna. Technika ta łączona jest z innymi algorytmami, które na kolejnych etapach decydują, czy wskazany obszar rzeczywiście zawiera poszukiwany obiekt. Do tego typu metod wykorzystywany jest m. in. algorytm *Mean shift* [10] i logika rozmyta [22].

Opisywana grupa metod może zostać użyta do detekcji zdeformowanych i pochylonych tablic. Rzadko występują one osobno w metodach detekcji, głównie ze względu na ich dużą czułość na zmiany naświetlenia. Dodatkowo w zależności od kraju oraz przeznaczenia pojazdu, kolory tablic mogą się znacznie różnić. Przykładowo obecnie w Polsce tablice aut elektrycznych mają kolor zielony, a samochody zabytkowe żółty (1.4).



Rysunek 1.4: Tablice rejestracyjne w Polsce dla aut elektrycznych i zabytkowych (źródło: opracowanie własne)

1.1.3 Metody oparte na teksturach (ang. *Texture based*)

Metody oparte na teksturach wykorzystują fakt znajdowania się znaków na tablicach rejestracyjnych. Znaki na tablicy mają z reguły czarny kolor i znajdują się na jasnym tle tworząc duży kontrast. Powyższa grupa algorytmów wykorzystuje wysoką częstość zmiany kolorów w obszarze występowania tablic rejestracyjnych. W [24] autorzy zaproponowali metodę lokalizacji tablic wykorzystując algorytm kwantyzacji wektorów (ang. *Vector Quantization - VQ*). W przeciwieństwie do innych metod, które wykorzystywały krawędzi lub kontrast, metoda VQ wykorzystuje aktualną zawartość tablicy rejestracyjnej. Autorzy wykorzystali bardzo wysoką skuteczność na poziomie 98%.

W analizie tekstur, często stosuje się filtr Gabora. Jest to filtr liniowy, pozwalający na przefiltrowanie obrazu z precyzyjnie dobranym zakresem częstotliwości. Reprezentacje częstotliwości i orientacji filtrów Gabora są uważane przez wielu współczesnych naukowców zajmujących się widzeniem komputerowym za podobne do tych z ludzkiego układu wzrokowego [13]. W [2] zaprezentowano algorytm wykorzystujący filtr Gabora. Jest to jednak metoda czasochłonna i nie znajduje zastosowania dla systemów, w których szybkość działania jest jednym z najistotniejszych czynników.

Wszystkie metody oparte na teksturach są odporne na deformacje tablic. Jest to kluczowa zaleta ich stosowania. Mimo to, metody te wymagają skomplikowanych obliczeń i nie dają zadowalających efektów w złożonych środowiskach z różnymi warunkami oświetlenia.

1.1.4 Klasyfikatory

Wiele badań wykorzystuje cechy Haara razem ze wzmocnieniem adaptacyjnym (ang. *Adaptive Boosting - AdaBoost*) do wyuczenia kaskady klasyfikatorów. Podejście takie zostało zaproponowane po raz pierwszy w [21]. Algorytm Viola-Jones został zaprezentowany w 2001. Pomimo upływu ponad 20 lat, dalej jest on powszechnie stosowany co świadczy o jego ponadczasowości i uniwersalności. Autorzy zaprojektowali go jako detektor twarzy, jednak jego funkcjonalność pozwala na wykrywanie dowolnych obiektów, np. tablic rejestracyjnych, przy odpowiednim wyuczeniu. Aby przedstawić jak działa algorytm Viola-Jones, należy najpierw zrozumieć czym są cechy Haara. Cechy Haara często są przedstawiane jako skalowalne, prostokątne szablony (rysunek 1.5), używane do porównania zależności pomiędzy pikselami, w szczególności jak ciemne są one względem siebie. Wartość cechy obliczana jest jako różnica pomiędzy średnią jasnością pikseli w zbiorze “białym” i średnią jasnością pikseli w zbiorze “czarnym”.




Rysunek 1.5: Cechy Haara używane w algorytmie Viola-Jones (źródło: https://docs.opencv.org/4.x/d2/d99/tutorial_js_face_detection.html)

Podejście takie powoduje jednak, że dla detektora o rozdzielczości 24x24px, algorytm

wymaga obliczenia ponad 180000 cech. Z tego powodu autorzy wprowadzili nowe pojęcie obrazu całkowego (ang. *integral image*).

Twierdzenie 1.1.2 Obrazem całkowym nazywamy tablicę dwuwymiarową o rozmiarze obrazu źródłowego, w której każdy element w i -tym wierszu i j -tej kolumnie przechowuje sumę pikseli z tej części obrazu, której prawym dolnym wierzchołkiem jest piksel (i, j) (rysunek 1.6).



Rysunek 1.6: Obraz całkowy dla punktu (i, j) (źródło: <https://www.spoj.com/WIPING5/problems/WIPING50.pdf>)

Matematycznie obraz całkowy $ii(x, y)$ przedstawiamy jako:

$$ii(x, y) = \sum_{1 \leq j \leq x} \sum_{1 \leq k \leq y} i(j, k) \quad (1.2)$$

Natomiast obliczanie obrazu całkowego z definicji 1.2 dla każdego punktu w obrazie jest czasochłonne i charakteryzuje się złożonością obliczeniową $O(n_x^2 n_y^2)$. Aby osiągnąć złożoność niezależną od rozmiaru okna, sumę oblicza się odejmując od sumy wartości obrazu całkowego dla prawego dolnego i lewego górnego wierzchołka sumę wartości obrazu dla pozostałych wierzchołków analizowanego prostokąta. Poniżej przedstawiono obliczenie sumy dla prostokąta rozpiętego między punktami (x_1, y_1) , a (x_2, y_2) .

$$\sum_{x_1 \leq x \leq x_2} \sum_{y_1 \leq y \leq y_2} i(x, y) = ii(x_2, y_2) - ii(x_1 - 1, y_2) - ii(x_2, y_1 - 1) + ii(x_1 - 1, y_1 - 1) \quad (1.3)$$

Na podstawie powyższego wzoru można zauważyć, że wystarczą operacje tylko na 4 punktach obrazu całkowego. Ten sposób charakteryzuje się liniową złożonością obliczeniową $O(1)$. Dla obliczenia różnicy pomiędzy sumami dwóch dowolnych prostokątów wymagane jest pobranie wartości dla 8 punktów z obrazu całkowego.

Algorytm Viola-Jones wymaga dużej ilości próbek pozytywnych i negatywnych. Do wyuczenia klasyfikatora i wybrania zbioru cech zastosowano algorytm AdaBoost. Autorzy zaproponowali użycie kaskady klasyfikatorów. Takie podejście bazuje na obserwacji, że okna pozytywne stanowią średnio 0.01% wszystkich okien. Rozpatrywane okno w pierwszej kolejności badane jest przez słabsze klasyfikatory, które bazują na mniejszej liczbie cech. Dzięki takiemu podejściu algorytm stał się bardziej wydajny czasowo. Każdy kolejny klasyfikator w kaskadzie oblicza większą liczbę cech. Jeżeli na którymś etapie klasyfikator zwróci odpowiedź negatywną, proces jest przerywany. Do osiągnięcia pozytywnego wyniku, wymagane jest zwrócenie przez wszystkie klasyfikatory odpowiedzi pozytywnej. W algorytmie Viola-Jones kaskada składa się z 32 klasyfikatorów, które

badają od 2 do 200 cech. Łącznie liczone jest 4297 cech, co daje średnio 8 cech na klasyfikator. W trakcie uczenia każdy z klasyfikatorów ma przypisany indywidualny próg decyzyjny. Każdy etap kaskady uczony jest w ramach boostingu (np. poprzez AdaBoost lub RealBoost).

AdaBoost (Adaptive Boosting) jest popularną techniką wzmacniania, której zadaniem jest stworzenie mocnego klasyfikatora na podstawie wielu słabych klasyfikatorów. Słabym klasyfikatorem nazywamy klasyfikator, który osiąga niską dokładność, jednak wyższą od losowych wyników. Za przykład może posłużyć rozpoznawanie płci na podstawie wzrostu. Słaby klasyfikator mógłby bazować na założeniu, że każda osoba o wzroście 175cm lub wyższym jest mężczyzną. Pozostała grupa osób jest kobietami. Wiele osób ze zbioru testowego zostanie określonych błędnie, jednak dokładność klasyfikatora będzie wyższa niż 50%.

AdaBoost jest techniką, która może zostać łączona z dowolnym algorytmem klasyfikującym, jednak nie może zostać wykorzystany jako samodzielny klasyfikator. Po raz pierwszy został on przedstawiony w [7]. AdaBoost występuje w połączeniu z popularnymi wariantami słabych klasyfikatorów [27]:

- AdaBoost + decision stump
- AdaBoost + drzewka decyzyjne
- AdaBoost + klasyfikator liniowy (np. SVM)
- AdaBoost + naiwny Bayes

Głównymi zastosowaniami tej techniki jest wybór najlepszych cech z punktu widzenia klasyfikacji oraz dobór wag dla klasyfikatorów wchodzących w skład kaskady.

Każdy słaby klasyfikator powinien zostać wyuczony na losowym podzbiore zbioru uczącego. Podzbiory mogą się nakładać, natomiast nie powinno się dzielić zbiorów na równe części. AdaBoost przypisuje wagi do jednostek treningowych, które określają prawdopodobieństwo pojawienia się w zbiorze uczącym zgodnie ze wzorem 1.4.

$$D_{t+1}(i) = \frac{D_t(i) \exp(-\alpha_t y_i h_t(x_i))}{Z_t} \quad (1.4)$$

D_t oznaczono wektor wszystkich wag, natomiast Z_t reprezentuje ich sumę. Indeks i jest numerem kolejnej próbki w zbiorze uczącym. Na początku wszystkie próbki posiadają tą samą wartość wag. Po zakończeniu uczenia, wagi błędnie sklasyfikowanych próbek zostają zwiększone. Dzięki temu, w następnej iteracji uczenia kolejny klasyfikator będzie mógł lepiej rozpoznawać niepoprawnie oznaczone jednostki treningowe w poprzednim kroku. W momencie, gdy każdy klasyfikator zostanie wyuczony, AdaBoost przypisuje do nich wagi na podstawie dokładności każdego z nich. Ostateczny klasyfikator można opisać wzorem 1.5.


$$H(x) = \text{sign}\left(\sum_{t=1}^T \alpha_t h_t(x)\right) \quad (1.5)$$

Finalny klasyfikator zawiera T słabych klasyfikatorów. Waga klasyfikatora, wyliczona przez AdaBoost, została określona symbolem α_t . Ostateczny rezultat powyższego równania można opisać jako liniowa kombinacja słabych klasyfikatorów.

Pierwszy klasyfikator ($t = 1$) jest trenowany z równym prawdopodobieństwem dla wszystkich próbek. Po zakończeniu uczenia, waga obliczana jest na podstawie wzoru 1.6.

$$\alpha_t = \frac{1}{2} \ln \frac{1 - \epsilon_t}{\epsilon_t} \quad (1.6)$$

Współczynnik α_t jest skorelowany z poziomem błędu klasyfikatora ϵ_t , który to jest liczony jako liczba błędnie sklasyfikowanych próbek dzielona przez rozmiar zbioru uczącego. Rysunek 1.7 przedstawia powyższą zależność.



Rysunek 1.7: Zależność współczynnika α od błędności klasyfikatora (źródło: https://chrisjmccormick.files.wordpress.com/2013/12/adaboost_alphacurve.png)

Z rysunku 1.7 można odczytać, że waga rośnie wykładniczo dla klasyfikatorów o wysokiej dokładności. Dla klasyfikatora o poziomie błędności 0.5 waga jest równa zero. Oznacza to, że taki klasyfikator jest równie dokładny co losowe zgadywanie, dlatego jest on ignorowany. Dla klasyfikatorów o większym poziomie błędności, waga przyjmuje wartość ujemną. Jeśli taki klasyfikator uzna próbkę za negatywną, ostatecznie zostanie ona oznaczona jako pozytywna.

AdaBoost jest techniką uczenia progresywnego. Ważne jest, aby na wejściu próbki uczące były odpowiedniej jakości. Metoda ta jest bardzo czuła na zakłócenia. Jednymi z najczęstszych aplikacji tego typu boostingu jest klasyfikacja tekstu oraz zdjęć.

Wzmocnienie AdaBoost spotykane jest w różnych wariantach. Jednym z nich jest Real AdaBoost, zwany również RealBoostem, zaprezentowany po raz pierwszy w [16]. Główną różnicą w stosunku do AdaBoosta, jest założenie, że słabe klasyfikatory są rzeczywistoliczbowe, a nie binarne [27]. Odpowiedź słabego klasyfikatora jest zwykle ustalana jako przybliżenie połowy przekształcenia logit:

$$f_t(X) = \frac{1}{2} \ln \frac{\hat{P}_w(y = 1|x)}{\hat{P}_w(y = -1|x)} \quad (1.7)$$

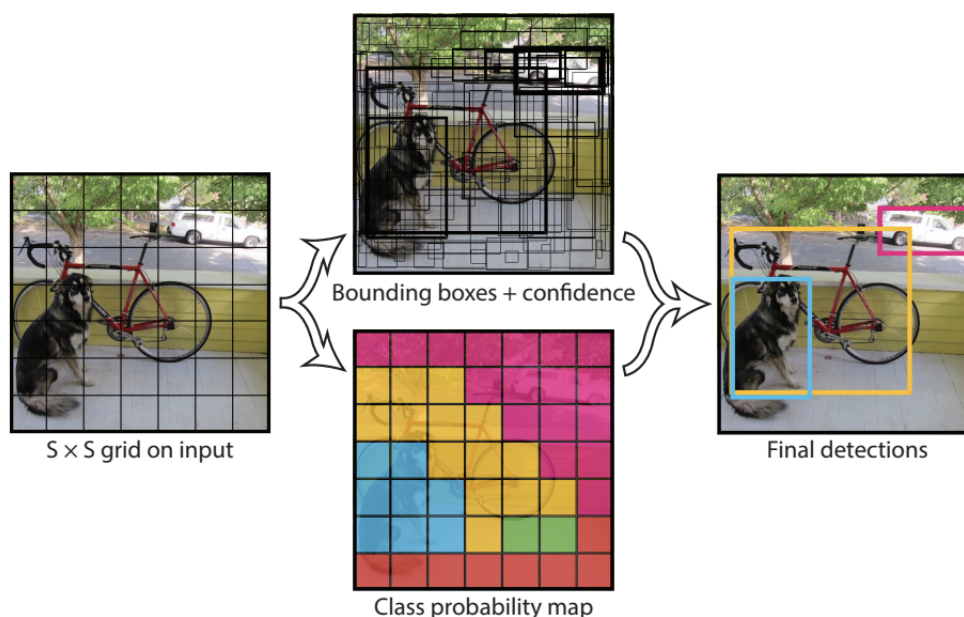
gdzie $\hat{P}_w(y = \pm 1|x)$ stanowi oszacowanie rozkładu klas warunkowego na x z wykorzystaniem aktualnych wag w_i . W przeciwieństwie do AdaBoost, słabe klasyfikatory nie

posiadają wag. Mechanizm ważenia słabych klasyfikator jest niejako wpleciony w same odpowiedzi rzeczywistoliczbowe. Możliwym jest wykazanie, że wyrażenie 1.7 jest rozwiązaniem zadania minimalizacji kryterium wykładniczego określonego poprzez rozkład w_i na zbiorze danych (tj. na konkretnej próbie). Analogicznie wyrażenie to jest również rozwiązaniem zadania minimalizacji kryterium wykładniczego określonego poprzez prawdziwy ale nieznany rozkład łączny generujący dane tj. $P(x, y) = p(x)P(y|x)$. Algorytm RealBoost posiada silne podobieństwa do techniki regresji logistycznej. Schemat reważenia w boostingu pracuje sposób pokrewny do rezyduów błędów (ang. *error residuals*).

1.1.5 Metody głębokiego uczenia (ang. *Deep learning*)

W związku z rozwojem dziedziny widzenia komputerowego oraz wzrostem mocy komputerów na przestrzeni ostatnich lat, wiele metod statystycznych zostało zastąpionych przez sieci neuronowe z powodu ich wysokiej skuteczności w detekcji obiektów. Jednym z zaproponowanych podejść jest użycie sieci konwolucyjnych (ang. *Convolutional Neural Network* - CNN)[17]. Składają się one z jednej lub wielu warstw konwolucyjnych (typowych dla kroku próbkowania, określającego subwzorce), a następnie przez jedną lub w pełni połączone warstwy tak jak w klasycznej wielowarstwowej sieci, np. MLP, SVM, SoftMax itp. Sieci konwolucyjne są łatwe do uczenia, gdyż zawierają mniej parametrów (wykorzystując te same wagi) niż typowe sieci neuronowe z dokładnością do ilości warstw konwolucyjnych i ich rozmiaru. Ten rodzaj sieci neuronowych jest predestynowany do obliczeń na strukturach 2D (tj. obrazy) [26].

Jednym z najnowocześniejszych systemów detekcji w czasie rzeczywistych jest algorytm YOLO (ang. *You only look once*) [15]. Algorytm jest bardzo wydajny. Bazuje na sieciach R-CNN. Autorzy zapewniają o możliwości przetwarzania 45 klatek na sekundę, a dla wersji szybszej, lecz o niższej dokładności, ponad 150 klatek na sekundę. Twórcom wzorca przyświecała idea “spojrzenia tylko raz”, wzorując się na postrzeganiu świata przez człowieka, który po jednym spojrzeniu na badany obraz, jest w stanie zidentyfikować konkretne obiekty. W przeciwieństwie do tradycyjnych metod z oknem przesuwным, YOLO podczas procesu uczenia i testowania otrzymuje na wejściu cały obraz. Na obraz wejściowy nałożona zostaje siatka o rozmiarze $S \times S$, która tworzy obwiednie, a następnie wykorzystuje je do rozpoznawania szukanych obiektów. Dla każdej uzyskanej ramki, mechanizm wyznacza prawdopodobną klasę. Ramki o prawdopodobieństwie wyższym od ustalonego progu, zostają nałożone na wejściowy obraz, najczęściej w postaci prostokątów otaczających obiekt. Rysunek 1.8 przedstawia opisany schemat. Ograniczenia YOLO wynikają z ograniczeń przestrzennych algorytmu. W zależności od wielkości siatki, system może mieć problem z wykryciem mniejszych obiektów takich jak np. stado ptaków. Algorytm jest stale udoskonalany przez autorów. Na moment pisania pracy, udostępniona została trzecia wersja systemu.



Rysunek 1.8: Algorytm YOLO (źródło: <https://towardsdatascience.com/r-cnn-fast-r-cnn-faster-r-cnn-yolo-object-detection-algorithms-36d53571365e>)

1.2 Przegląd istniejących metod segmentacji tablic rejestracyjnych

Drugim etapem w większości systemów Automatycznego Rozpoznawania Tablic Rejestracyjnych jest rozpoznanie znaków na tablicy rejestracyjnej zlokalizowanej w poprzednim kroku. Zanim dojdzie do klasyfikacji znaków, często są one wpierw segmentowane. Jest to szczególny przypadek optycznego rozpoznawania znaków. Wiele krajów posiada ścisłe regulacje na temat czcionki i kolorów tablicy rejestracyjnej. Przepisy te mają na celu zwiększenie czytelności znaków identyfikujących każdy pojazd. W Polsce, jak i większości krajów na świecie, tablice pokryte są specjalną warstwą refleksyjną odbijającą światło. Działanie takie zwiększa ich czytelność dla ludzkiego oka w gorszych warunkach oświetleniowych. Dla aparatów fotograficznych ta cecha tablic często powoduje nieczytelność tablic na wykonanym zdjęciu. Tablica odbija na tyle dużą ilość światła, co skutkuje powstaniem na zdjęciu białego prostokąta w miejscu tablicy. Przykład takiego obrazu przedstawia rysunek 1.9.



Rysunek 1.9: Refleks świetlny występujący w niewystarczających warunkach oświetleniowych (źródło: opracowanie własne)

Poza powyższymi trudnościami, tablice mogą być obrócone lub uszkodzone. Aby zwiększyć w jak największym stopniu prawdopodobieństwo prawidłowego odczytania znaków, używa się szeregu czynności na obrazie wejściowym. Dla obróconych obiektów stosuje się transformatę biliniową, zwaną również metodą Tustina [23].

1.2.1 Binarizacja

W wielu klasycznych metodach widzenia komputerowego, w celu segmentacji znaków, stosuje się binaryzację. W zbinaryzowanym obrazie łatwiej jest rozdzielić znaki w porównaniu do obrazu kolorowego lub w skali szarości. Podstawowym problemem tej techniki jest odpowiedni dobór wartości progu. Wybór ten jest dokonywany w oparciu o różne metody, które można podzielić na zmiennoprogowe i automatyczne. Jednakże, wyznaczenie progu binaryzacji musi zostać wykonane właściwie, w celu uniknięcia połączenia znaków lub scalenia ich z obramowaniem tablicy rejestracyjnej [5]. Jednym z częściej stosowanych metod binaryzacji jest progowanie adaptacyjne (ang. *Adaptive Thresholding*). Stosuje się to w momencie kiedy różne obszary obrazu mogą charakteryzować się różnymi warunkami oświetlenia i stosowanie stałej wartości nie dałoby zadowalających efektów. Algorytm wyznacza próg dla konkretnego piksela na podstawie niewielkiego regionu wokoło. Dla tego samego obrazu wyliczane są różne wartości progu dla różnych regionów co prowadzi do uzyskania lepszych wyników niż w przypadku stałego progu binaryzacji. Na rysunku 1.10 przedstawiono przykłady binaryzacji obrazu stałym progiem globalnym i progiem wyznaczonym adaptacyjnie.



Rysunek 1.10: Przykład binaryzacji obrazu przy niejednorodnym oświetleniu za pomocą globalnego i lokalnego progu (źródło: https://docs.opencv.org/3.4/d7/d4d/tutorial_py_thresholding.html)

Algorytm progowania adaptacyjnego otrzymuje najczęściej na wejściu obraz w skali szarości lub kolorowy. Próg jest wyliczany dla wszystkich pikseli w obrazie z osobna. Jednym ze znanych podejść jest to zaproponowane przez Chow i Kaneko [4]. W tym przypadku obraz dzielony jest na zbiór nakładających się fragmentów. Optymalny próg wyznaczy jest dla konkretnego fragmentu na podstawie analizy histogramu. Próg dla każdego piksela wyliczany jest na podstawie interpolacji wyników dla odpowiedniego fragmentu. Wadą tej metody jest jej złożoność obliczeniowa. Jest to jeden z głównych powodów, dlaczego algorytm ten nie znalazł zastosowania w aplikacjach działających w czasie rzeczywistym.

Alternatywnym podejściem do znalezienia lokalnego progu jest statystyczne zbadanie intensywności lokalnego sąsiedztwa każdego piksela. Wybór metody statystycznej jest skorelowany z obrazem wejściowym. Najczęściej używa się średniej, mediany, średniej z wartości maksymalnej i minimalnej badanego otoczenia lub funkcji Gaussa. Dobór wielkości sąsiedztwa ma duży wpływ na wyliczenie progu. Rozmiar musi być na tyle duży, aby zawierać zarówno piksele tła jak i badanego obiektu. Z drugiej strony wybranie zbyt dużych obszarów może naruszyć założenie o równomiernym oświetleniu rozpatrywanego fragmentu. Ten rodzaj adaptacyjnego progowania jest bardziej wydajny od algorytmu Chow i Kaneko. Charakteryzuje się wysoką jakością oddzielania obiektów od tła i znajduje szerokie zastosowanie w wielu aplikacjach.

Innym znanym algorytmem stosowanym do wyznaczania progu binaryzacji jest algorytm Otsu [14]. Metoda Otsu jest techniką opartą na wariancji w celu znalezienia wartości progowej, przy której ważona wariancja między pikselami pierwszego planu i tła jest najmniejsza [30]. Kluczową ideą jest tutaj iteracja przez wszystkie możliwe wartości progu i pomiar rozproszenia pikseli tła i pierwszego planu. Następnie znajdowany jest próg, w którym rozproszenie jest najmniejsze. Algorytm iteracyjnie wyszukuje próg, który minimalizuje wariancję wewnątrz klasy, zdefiniowaną jako ważona suma wariancji dwóch klas (tła i pierwszego planu). Kolory w skali szarości zwykle mieszczą się w zakresie 0-255. Tak więc, jeśli wybierzemy próg 100, to wszystkie piksele o wartościach mniejszych niż 100 staną się tłem, a wszystkie piksele o wartościach większych lub równych 100 staną się pierwszym planem obrazu. Wzór na znalezienie wariancji wewnątrzklasowej przy dowolnym progu t jest określony wzorem 1.8

$$\sigma^2(t) = \omega_{bg}(t)\sigma_{bg}^2(t) + \omega_{fg}(t)\sigma_{fg}^2(t) \quad (1.8)$$

gdzie $\omega_{bg}(t)$ i $\omega_{fg}(t)$ reprezentują prawdopodobieństwo liczby pikseli dla każdej klasy przy progu t , natomiast σ^2 oznaczono wariancję wartości kolorów. Wyliczanie wariancji dla konkretnej klasy pikseli przedstawiono na wzorze 1.9.

$$\sigma_{bg|fg}^2(t) = \frac{\sum (x_i - \hat{x})^2}{N - 1} \quad (1.9)$$

Wartość piksela odpowiedniej klasy reprezentuje symbol x_i , natomiast \hat{x} reprezentuje średnią pikseli rozpatrywanej klasy. Liczbę wszystkich pikseli zapisano literą N .

Metoda Otsu implementowana przez wiele środowisk obliczeniowych (np. MATLAB) [12]. Algorytm szczególnie dobrze sprawdza się w przypadkach, gdy liczby pikseli tła i obiektów pierwszego planu są zbliżone [18].

1.2.2 Metoda k-średnich

todo

1.2.3 Metoda rzutów jasności

todo

1.2.4 Metoda elementów połączonych (ang. *Connected components*)

todo

1.3 Przegląd istniejących metod rozpoznawania tablic rejestracyjnych

1.3.1 OCR

tesseract korzysta z sieci lstm wiec warto by to opisac i jakieś inne sieci <https://bulldogjob.pl/readme/3-typy-rekurencyjnych-sieci-neuronowych>

1.3.2 TEMPLATE AND PATTERN MATCHING TECHNIQUES

2. Zebranie materiału uczącego

3. Opracowany algorytm

3.1 Proces uczenia klasyfikatora

@todo

3.2 Schemat algorytmu

@todo diagram graficzny

3.3 Biblioteki użyte w programie

Środowisko Python jest niezwykle popularne m.in. ze względu na mnogość dostępnych gotowych bibliotek. Jednym z celów pracy było zaimplementowanie algorytmu uczącego i klasyfikującego. Cel ten udało się zrealizować, natomiast nie byłoby to możliwe bez użycia gotowych rozwiązań do elementarnych operacji t.j. listowanie plików w katalogach, odczyt i zapis zdjęć, pobieranie pojedynczych klatek z filmu wideo czy operacje na tablicach. Poniżej wymieniono i opisano najważniejsze oraz najczęściej używane biblioteki w opisywanej pracy.

3.3.1 OpenCV

OpenCV jest biblioteką o otwartym źródle (ang. *open source*) [28, 29]. Do jej głównych zastosowań należą przetwarzanie obrazów oraz uczenie maszynowe. W przedstawionym programie wykorzystano najnowszą dostępną wersję na moment pisanie pracy 4.6.0. Została zaprojektowana, aby zapewnić ustandaryzowaną infrastrukturę dla aplikacji widzenia komputerowego. Oprogramowanie dystrybuowane jest na licencji BSD. Pierwsza wersja została opracowana w roku 1999. Oryginalnie powstała w języku C++, natomiast istnieją biblioteki pozwalające używać jej w innych językach programowania. Bibliotekę można podzielić na kilka głównych modułów:

- Przetwarzanie obrazów - moduł zawiera zestaw metod do przeprowadzania takich operacji jak filtrowanie, przekształcenia geometryczne, zmiana przestrzeni kolorów, histogramy
- Przetwarzanie wideo - zestaw metod, które pozwalają na m. in. usuwanie tła, śledzenie obiektów, wykrywanie ruchu
- Operacje wejścia/wyjścia na wideo - wyciąganie poszczególnych klatek z wideo, kodowanie, zapis i odczyt wideo
- HighGUI - moduł służący do wizualizacji wyników, wyświetlania okien, zaznaczania ROI (ang. *Region of interest*)

Poniżej wymieniono użyte w stworzonym programie funkcje wraz z krótkim opisem ich zastosowania:

- *videoCapture* - przechwytywanie obrazów z pliku wideo
- *cvtColor* - zmiana przestrzeni barw w obrazie
- *imread* - wczytanie obrazu z pliku
- *imshow* - wyświetlenie obrazu
- *imwrite* - zapis obrazu do pliku
- *rectangle* - rysowanie prostokąta na obrazie
- *putText* - umiejscowienie tekstu na obrazie
- *addWeighted* - połączenie dwóch obrazów poprzez nałożenie ich na siebie
- *thresholding* - binaryzacja obrazu
- *GaussianBlur* - wygładzanie obrazu za pomocą funkcji Gaussa
- *Canny* - wykrywanie krawędzi za pomocą algorytmu Johna F. Canny’ego [3]
- *findContours* - wykrywanie konturów obiektów (punktów o tym samym kolorze lub intensywności łączących się w krzywe)
- *resize* - zmiana wielkości obrazu
- *imdecode* - odczytywanie zdjęcia z bufora

3.3.2 Tesseract OCR

Biblioteka Tesseract jest pakietem składającym się z programu lini poleceń *tesseract* oraz silnika OCR *libtesseract* [31]. Tesseract powstał między rokiem 1985, a 1994 na potrzeby firmy Hewlett-Packard. W roku 2005 firma upubliczniła bibliotekę jako rozwiązanie *open-source*. Od początku 2006 do listopada 2018 za rozwój Tesseract odpowiedzialna była firma Google. Obecnie głównym programistą projektu jest Ray Smith. Silnik programu oparty jest o język programowania C++. W celu wykorzystania jej w opisywanym programie, użyto nakładki *pytesseract* [25]. Autorzy deklarują, że najnowsza wersja 5, wydana w listopadzie 2021, wspiera ponad 100 języków. Biblioteka wykorzystuje rekurencyjne sieci neuronowe LSTM (ang. *Long Short-Temp Memory*) [9].

3.3.3 Numpy

3.3.4 Sklearn

3.3.5 Matplotlib

4. Wyniki badań

Podsumowanie

Podsumowanie pracy powinno na maksymalnie dwóch stronach przedstawić główne wyniki pracy dyplomowej. Struktura zakończenia to:

1. Przypomnienie celu i hipotez
2. Co w pracy wykonano by cel osiągnąć (analiza, projekt, oprogramowanie, badania eksperymentalne)
3. Omówienie głównych wyników pracy
4. Jak wyniki wzbogacają dziedzinę
5. Zamknięcie np. poprzez wskazanie dalszych kierunków badań.

Spis literatury

Książki

Artykuły

- [1] C.N.E. Anagnostopoulos i in. “A License Plate-Recognition Algorithm for Intelligent Transportation System Applications”. W: *IEEE Transactions on Intelligent Transportation Systems* 7.3 (2006), s. 377–392. DOI: 10.1109/TITS.2006.880641.
- [2] Hakan Caner, Hatice Geçim i Ali Alkar. “Efficient Embedded Neural-Network-Based License Plate Recognition System”. W: *Vehicular Technology, IEEE Transactions on* 57 (paź. 2008), s. 2675–2683. DOI: 10.1109/TVT.2008.915524.
- [3] John Canny. “A Computational Approach to Edge Detection”. W: *IEEE Transactions on Pattern Analysis and Machine Intelligence* PAMI-8.6 (1986), s. 679–698. DOI: 10.1109/TPAMI.1986.4767851.
- [4] C. K. Chow i T. Kaneko. “Boundary Detection of Radiographic Images by a Threshold Method”. W: *IFIP Congress*. 1971.
- [5] Shan Du i in. “Automatic License Plate Recognition (ALPR): A State-of-the-Art Review”. W: *IEEE Transactions on Circuits and Systems for Video Technology* 23.2 (2013), s. 311–325. DOI: 10.1109/TCSVT.2012.2203741.
- [6] Tran Duc Duan i in. “Building an Automatic Vehicle License-Plate Recognition System”. W:
- [7] Yoav Freund i Robert E. Schapire. “Experiments with a New Boosting Algorithm”. W: *ICML*. 1996.
- [8] Gisu Heo i in. “Extraction of Car License Plate Regions Using Line Grouping and Edge Density Methods”. W: *2007 International Symposium on Information Technology Convergence (ISITC 2007)*. 2007, s. 37–42. DOI: 10.1109/ISITC.2007.79.
- [9] Sepp Hochreiter i Jürgen Schmidhuber. “Long Short-term Memory”. W: *Neural computation* 9 (grud. 1997), s. 1735–80. DOI: 10.1162/neco.1997.9.8.1735.
- [10] Wenjing Jia i in. “Mean shift for accurate license plate localization”. W: *Proceedings. 2005 IEEE Intelligent Transportation Systems, 2005*. 2005, s. 566–571. DOI: 10.1109/ITSC.2005.1520110.

- [11] Xin Lin i Kazunori Otobe. "Hough transform algorithm for real-time pattern recognition using an artificial retina camera". W: *Opt. Express* 8.9 (kw. 2001), s. 503–508. DOI: 10.1364/OE.8.000503. URL: <http://opg.optica.org/oe/abstract.cfm?URI=oe-8-9-503>.
- [12] Adam Lipiński i Seweryn Lipiński. "Automatyczna ocena jakości oprysku na podstawie śladów kropeł przy użyciu komputerowej analizy obrazu". W: *Inżynieria Rolnicza* 13 (sty. 2009), s. 163–168.
- [13] Bruno Olshausen i David Field. "Emergence of simple-cell receptive field properties by learning a sparse code for natural images". W: *Nature* 381 (lip. 1996), s. 607–9. DOI: 10.1038/381607a0.
- [14] Nobuyuki Otsu. "A Threshold Selection Method from Gray-Level Histograms". W: *IEEE Transactions on Systems, Man, and Cybernetics* 9.1 (1979), s. 62–66. DOI: 10.1109/TSMC.1979.4310076.
- [15] Joseph Redmon i in. "You Only Look Once: Unified, Real-Time Object Detection". W: *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, s. 779–788. DOI: 10.1109/CVPR.2016.91.
- [16] Robert E. Schapire i Yoram Singer. "Improved Boosting Algorithms Using Confidence-Rated Predictions". W: *Mach. Learn.* 37.3 (grud. 1999), s. 297–336. ISSN: 0885-6125. DOI: 10.1023/A:1007614523901. URL: <https://doi.org/10.1023/A:1007614523901>.
- [17] Zied Selmi, Mohamed Ben Halima i Adel Alimi. "Deep Learning System for Automatic License Plate Detection and Recognition". W: list. 2017, s. 1132–1138. DOI: 10.1109/ICDAR.2017.187.
- [18] M. Sezgin i Bulent Sankur. "Survey over image thresholding techniques and quantitative performance evaluation". W: *Journal of Electronic Imaging* 13 (sty. 2004), s. 146–168. DOI: 10.1117/1.1631315.
- [19] Jithmi Shashirangana i in. "Automated License Plate Recognition: A Survey on Methods and Techniques". W: *IEEE Access* 9 (2021), s. 11203–11225. DOI: 10.1109/ACCESS.2020.3047929.
- [20] Fayeze Tarsha-Kurdi. "HOUGH-TRANSFORM AND EXTENDED RANSAC ALGORITHMS FOR AUTOMATIC DETECTION OF 3D BUILDING ROOF PLANES FROM LIDAR DATA". W: (wrz. 2007).
- [21] P. Viola i M. Jones. "Rapid object detection using a boosted cascade of simple features". W: *Proceedings of the 2001 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. CVPR 2001*. T. 1. 2001, s. I–I. DOI: 10.1109/CVPR.2001.990517.
- [22] Feng Wang i in. "Fuzzy-based algorithm for color recognition of license plates". W: *Pattern Recognit. Lett.* 29 (2008), s. 1007–1020.
- [23] Xiao-wei Xu i in. "A method of multi-view vehicle license plates location based on rectangle features". W: *2006 8th international Conference on Signal Processing* 3 (2006), s. 1–4.

- [24] R. Zunino i S. Rovetta. "Vector quantization for license-plate location and image coding". W: *IEEE Transactions on Industrial Electronics* 47.1 (2000), s. 159–167. DOI: 10.1109/41.824138.

Źródła internetowe i inne

- [25] *A Python wrapper for Google Tesseract*. URL: <https://github.com/madmaze/pytesseract>.
- [26] Adrian Horzyk. *Uczenie głębokich sieci neuronowych*. URL: <https://home.agh.edu.pl/~horzyk/lectures/miw/MIW-UczenieG%c5%82%c4%99bokichSieciNeuronowych.pdf>.
- [27] Przemysław Klęsk. *Techniki szybkiej detekcji: ekstrakcja cech poprzez obrazy całkowite, boosting, kaskady klasyfikatorów*. URL: https://wikizmsi.zut.edu.pl/uploads/4/4a/Szybka_detekcja.pdf.
- [28] *OpenCV documentation*. URL: <https://docs.opencv.org/4.x/>.
- [29] *OpenCV overview*. URL: <https://opencv.org/about/>.
- [30] *Otsu's method for image thresholding explained and implemented*. URL: <https://muthu.co/otsus-method-for-image-thresholding-explained-and-implemented/>.
- [31] *Tesseract Open Source OCR Engine*. URL: <https://github.com/tesseract-ocr/tesseract>.